治理失效，多半不是技术不够强

一页纸 · v1
11 个模块 / 96,444 字 的抽象

核 心 论 点

治理失效的多数根因，不是技术不够强，
而是「问题没被定义对」和「指标被单方向博弈」。

所以这套框架不回答「用什么模型」，只回答三件事：**问题怎么被定义 · 责任怎么被分配 · 结果怎么被度量**

01 五个反直觉的判断

框架的立论基础

1 发现与定义问题，比解决问题更难，也更重要。
解决问题技术驱动、最容易量化；发现与定义依赖经验与价值取向。组织因奖励可量化产出而**结构性偏科**：打击力持续变强，却永远慢半拍。→ 只有感知层能在问题规模化之前介入。

2 治理的上限由「接口质量」决定，不是单点技术。
五个交接点各有契约：可定义 / 可判定 / 可校准 / 可归因 / 可追溯。**最好的模型接在最差的接口上，整体仍然是差的。**

3 指标一旦进入考核，就不再是度量工具，而是行为契约。
四类博弈：摊薄、缩量、搬迁、篡改。最锋利的一条是「方向不可逆」——**任何少做事就能改善的指标，最终一定会被发现并利用。**

4 规则必须决定自己「住在哪里」。
由 `变更频率 × 证据具体程度` 决定进 Prompt / 检索库 / 权重 / 判例库。推论：**写不出一条规则的具体证据，就不该把它转给策略团队。**

5 对抗是常态，不是异常。
胜负由攻防迭代速度的**相对差**决定：`Δ = 平台迭代周期 − 对手变异周期`。Δ 远大于 0 时，纯语义匹配必然失效。→ 内容可伪装，行为与关系难伪装。

02 五层链路：一张责任分配表

链路的每一环，责任人不同

① 输入层	约束从哪来 底线 vs 水位
② 定义层	问题定义 标签 · 口径
③ 实现层	吞吐 · 成本 误伤上限
④ 执行层	召回 · 审核 质检
⑤ 回流层	申诉是唯一 的证伪机制

⚠ **头号失效原因：跨环节的指标错配 —— 用策略指标考核规则、用审核指标考核策略，各自最优、整体最差。**

03 三个贯穿机制

A 对抗与博弈 四层防御，顺序重要：提高规避成本 > 输入规范化 > 判定韧性 > 感知迭代。**L1 最有效却最少被用**——它不是算法问题，是业务与法务问题。